Datenbanken

—

Mehrbenutzerbetrieb

Thomas Studer

Institut für Informatik
Universität Bern

Einführung

Überweisung eines Betrags von einem Bankkonto `A` auf ein anderes Bankkonto `B`

1. Lastschrift des Betrags auf Konto `A`,
2. Gutschrift des Betrags auf Konto `B`.

ACID Postulate

Atomicity Die Änderungen einer Transaktion auf der Datenbank sind *atomar*, d.h. es werden alle oder keine dieser Operationen ausgeführt.

Consistency Eine Transaktion führt von einem *korrekten* DB-Zustand wieder in einen korrekten DB-Zustand über.

Isolation Eine Transaktion arbeitet *isoliert* auf der DB. Dies bedeutet, sie wird bei simultaner Ausführung weiterer Transaktionen von diesen nicht beeinflusst.

Durability Wirksame Änderungen von T sind *dauerhaft*, d.h. sie dürfen auch im Fall einer späteren Fehlfunktion nicht mehr verloren gehen.

Grundoperationen

`READ(X)` Transferiert die Daten `X` von der Datenbank auf einen lokalen Puffer, der zur Transaktion gehört, welche `READ(X)` ausführt.

`WRITE(X)` Transferiert die Daten `X` vom lokalen Puffer, der zur Transaktion gehört, welche `WRITE(X)` ausführt, zurück auf die Datenbank.

Wir können nun die Überweisung von CHF 50 von Konto `A` auf Konto `B` folgendermassen beschreiben:

```
READ(A)
A := A-50
WRITE(A)
READ(B)
B := B+50
WRITE(B)
```

Transaktionsmodell

aktiv	Anfangszustand; während die Operationen der Transaktion ausgeführt werden, bleibt sie in diesem Zustand.
wartend	Zustand, in welchem die Transaktion warten muss, bis benötigte Ressourcen (durch andere Transaktionen) freigegeben werden.
abgeschlossen	Zustand nach Ausführung der letzten Operation der Transaktion. Aus diesem Zustand kann die Transaktion immer noch scheitern, da möglicherweise die Daten nicht persistent geschrieben werden können.
gescheitert	Zustand, nachdem festgestellt worden ist, dass eine weitere Ausführung der Transaktion nicht mehr möglich ist.
aufgegeben	Zustand nach dem Rollback der Transaktion und Wiederherstellung der DB wie vor Beginn der Transaktion.
persistent	Zustand nach erfolgreicher Durchführung der Transaktion.

Zustandsübergangsdiagramm

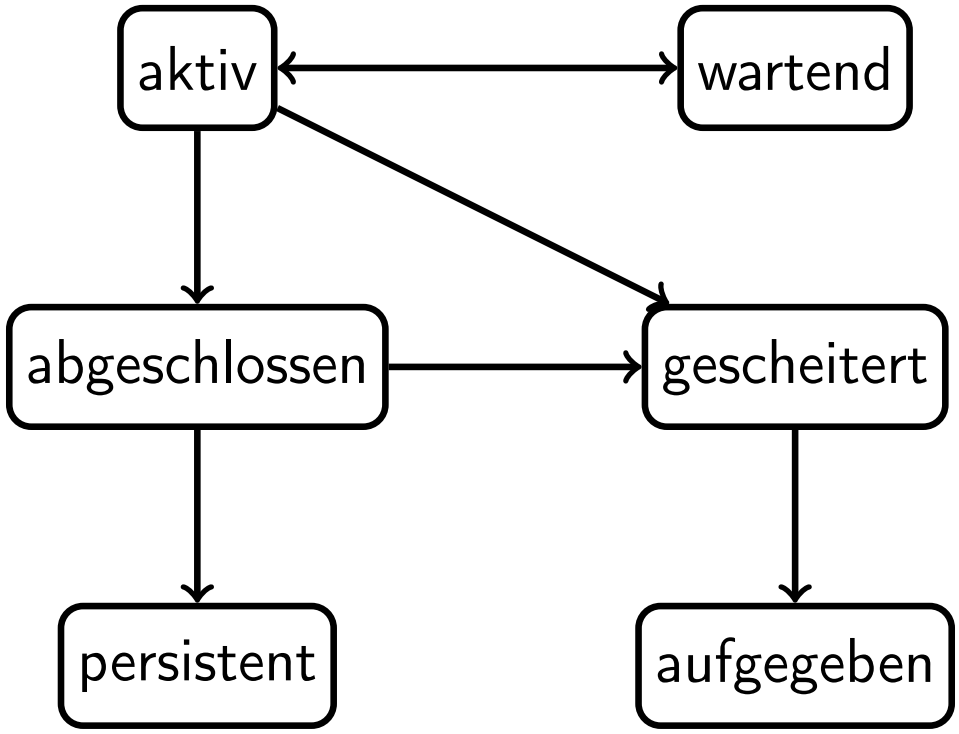

AUTO-COMMIT

In PostgreSQL wird standardmässig jede Anweisung als einzelne Transaktion ausgeführt.

Eine Anweisung, eine Transaktion, aber mehrere Änderungsoperationen

```
UPDATE Konti
SET Stand = Stand * 1.02
```

SQL

1. Mit `BEGIN` wird eine neue Transaktion gestartet. Damit ist für die folgenden Anweisungen der `AUTO-COMMIT` Modus ausgeschaltet.
2. Den erfolgreichen Abschluss einer Transaktion geben wir mit der Anweisung `COMMIT` an.
3. Wir können eine Transaktion aufgeben mit der Anweisung `ROLLBACK`. Die Datenbank wird dann in den ursprünglichen Zustand (vor Beginn der Transaktion) zurückgesetzt.

Nach einem `COMMIT` oder `ROLLBACK` beginnt eine neue Transaktion. Ohne erneute Angabe des Schlüsselwortes `BEGIN` ist diese neue Transaktion wieder im `AUTO-COMMIT` Modus.

```
BEGIN;
UPDATE Konti SET Stand = Stand - 50 WHERE KId = 'A';
UPDATE Konti SET Stand = Stand + 50 WHERE KId = 'B';
COMMIT;
```

Gegenseitige Fremdschlüssel

```
CREATE TABLE Autos (
       AutoId integer PRIMARY KEY,
       PaarId integer UNIQUE );

CREATE TABLE Personen (
       PersId integer PRIMARY KEY,
       PaarId integer UNIQUE
         REFERENCES Autos(PaarId) DEFERRABLE );

ALTER TABLE Autos ADD
  FOREIGN KEY (PaarId)
    REFERENCES Personen(PaarId) DEFERRABLE
```

Aufgeschobene Constraints

```
BEGIN;
SET CONSTRAINTS ALL DEFERRED;
INSERT INTO Autos VALUES (1,3);
INSERT INTO Personen VALUES (2,3);
COMMIT;
```

Dirty Reads

Eine Abfrage innerhalb einer Transaktion liefert das Ergebnis einer anderen Transaktion, die noch nicht persistent ist. Dies kann zu zwei Problemen führen:

1. Das Ergebnis kann inkonsistent sein.
2. Die schreibende Transaktion könnte abgebrochen werden. Dann würde das Ergebnis nicht mehr existieren (bzw. hätte gar nie existiert).

Folgende verzahnte Ausführung zweier Transaktionen zeigt das Problem. Wir verwenden wiederum die abstrakten `READ(X)` und `WRITE(X)` Operationen:

T1	T2
	READ(A)
	...
	WRITE(A)
READ(A)	
...	
	ROLLBACK

Non-repeatable Reads

Innerhalb einer Transaktion wird eine Abfrage wiederholt und erhält beim zweiten Mal ein anderes Resultat.

```
T1          T2
READ(A)
            WRITE(A)
            WRITE(B)
            COMMIT
READ(B)
READ(A)
...
```

Die beiden `READ(A)` Anweisungen in `T1` liefern verschiedene Resultate, obwohl sie nur committete Daten lesen.

Phantome

Phantome treten auf, wenn innerhalb einer Transaktion eine Abfrage mit einer identischen Selektionsbedingung wiederholt wird und bei der zweiten Abfrage eine andere Menge von Tupeln selektiert wird.

```
T1                          T2
SELECT COUNT(*)
FROM Konti;
                            INSERT INTO Konti
                               VALUES ('C', 10);
                            COMMIT;
SELECT AVG(Stand)
FROM Konti;
```

Isolationsgrade gemäss SQL Standard

Isolationsgrad	Dirty R.	Non-repeatable R.	Phantome
READ UNCOMMITTED	Ja	Ja	Ja
READ COMMITTED	Nein	Ja	Ja
REPEATABLE READ	Nein	Nein	Ja
SERIALIZABLE	Nein	Nein	Nein

SET TRANSACTION ISOLATION LEVEL

```
BEGIN;
SET TRANSACTION ISOLATION LEVEL SERIALIZABLE;
SELECT COUNT(*) FROM Konti;
SELECT AVG(Stand) FROM Konti;
COMMIT;
```

Der Isolationsgrad muss dabei zwischen der `BEGIN` Anweisung und der ersten Anweisung der Transaktion gesetzt werden.

PostgreSQL vs. SQL Standard

PostgreSQL unterstützt den Isolationsgrad `READ UNCOMMITTED` nicht. Falls dieser Grad gesetzt wird, so wird intern `READ COMMITTED` verwendet.

Der SQL Standard definiert `SERIALIZABLE` als Default Wert für den Isolationsgrad. In PostgreSQL wird jedoch üblicherweise `READ COMMITTED` als Default verwendet.

Multiversion Concurrency Control Architektur MVCC

Grundidee

Jeder Benutzer sieht einen eigenen *Snapshot* der Datenbank zu einem bestimmten Zeitpunkt.

Die MVCC Architektur stellt sicher, dass

1. ein Lesezugriff niemals einen parallelen Schreibzugriff blockiert und
2. umgekehrt ein Lesezugriff niemals auf einen parallelen Schreibzugriff warten muss.

Implementierung

Jede Transaktion hat Transaktionsnummer `Xid`.

Zwei interne Attribute `Xmin` und `Xmax` bei jeder Tabelle:

1. `Xmin`: `Xid` der Trx, welche diese Version des Tupels erzeugt hat.
2. `Xmax`: `Xid` der Trx, welche diese Version als ungültig erklärt hat. Enthält `Null`, falls diese Version des Tupels noch gültig.

Ein Transaktion mit Transaktionsnummer `Xid` sieht ein Tupel `t`, falls gilt:

$$\texttt{t[Xmin]} \leq \texttt{Xid} \text{ und } (\texttt{t[Xmax] IS NULL} \text{ oder } \texttt{t[Xmax]} > \texttt{Xid}) \ .$$

Das heisst, das Tupel `t` wurde vor (oder in) der Transaktion `Xid` erzeugt und er wurde aus Sicht der Transaktion `Xid` noch nicht gelöscht.

Intern, aber sichtbar

```
SELECT txid_current()
```

```
SELECT *, Xmin, Xmax
FROM Konti
```

Bemerkung: Diese Anweisung zeigt nur die sichtbaren Tupel.

Beispiel

Wir starten mit Transaktionsnummer 1

```
INSERT INTO Konti VALUES ('A', 1000)
```

Konti

KId	Stand	Xmin	Xmax
A	1000	1	-

```
DELETE FROM Konti WHERE KId='A'
```

Konti

KId	Stand	Xmin	Xmax
A	1000	1	2

Achtung:

PostgreSQL verwendet 0 anstelle von `Null` für `Xmax` eines gültigen Tupels.

Beispiel 2

Konti

KId	Stand	Xmin	Xmax
A	2000	3	-

Mit Transaktionsnummer 4

```
UPDATE Konti
SET Stand=3000
WHERE KId='A'
```

Konti

KId	Stand	Xmin	Xmax
A	2000	3	4
A	3000	4	-

Rollback

Ein Rollback setzt nicht `Xmax` auf `Null` zurück, sondern merkt sich, dass die Transaktion abgebrochen wurde.

Interne Datenstruktur `pg_clog` enthält Status jeder Transaktion:

- 0 in Bearbeitung
- 1 abgebrochen
- 2 committed

`pg_clog`

XId	Status
3	2
4	2

ROLLBACK Beispiel

Transaktion mit Xid 5:

```
BEGIN;
DELETE FROM Konti WHERE KId='A';
ROLLBACK;
```

Konti

KId	Stand	Xmin	Xmax
A	2000	3	4
A	3000	4	5

pg_clog

XId	Status
3	2
4	2
5	1

Sichtbarkeitsbedingung

`T`: aktuelle Transaktion
`t`: Tupel, dessen Sichtbarkeit wir feststellen wollen

```
(Xmin == my-transaction &&          eingefügt in T
  (Xmax is null ||                  t wurde nicht gelöscht oder
    Xmax != my-transaction))        t wurde (nach T) gelöscht
||                                  oder
(Xmin is committed &&               Einfügen von t ist committed
  (Xmax is null ||                  t wurde nicht gelöscht oder
  (Xmax != my-transaction &&        t wurde gelöscht von T' aber
    Xmax is not committed)))        T' ist nicht committed
```

Read Committed

Dieser Isolationslevel verlangt, dass keine Dirty Reads auftreten.

- Vor jeder SQL Anweisung wird ein aktueller Snapshot erzeugt
- die Anweisung wird dann mit den Daten dieses Snapshots ausgeführt.

Die Sichtbarkeitsbedingung garantiert, dass jeder Snapshot nur Daten enthält, welche bereits committed wurden.

Parallele Schreibzugriffe

Die MVCC Architektur stellt sicher, dass Lese- und Schreibzugriffe sich nicht gegenseitig blockieren können.

Konflikte zwischen parallelen Schreibzugriffen lassen sich aber prinzipiell nicht vermeiden.

Beispiel

T2	T3
`BEGIN;`	
	`BEGIN;`
`UPDATE Konti`	
`SET Stand = Stand*2;`	
	`UPDATE Konti`
	`SET Stand = Stand*3;`
`COMMIT;`	
	`COMMIT;`

Vor Beginn der beiden Transaktionen hat das Konto `A` den `Stand` 1000 hat.
Nach der `UPDATE` Anweisung der Transaktion 2:

`Konti`

KId	Stand	Xmin	Xmax
A	1000	1	2
A	2000	2	-

`pg_clog`

XId	Status
1	2
2	0

Konsequenzen

Gemäss der Sichtbarkeitsbedingung sieht also Transaktion 3 für Konto `A` den `Stand` 1000.

Es bedeutet, dass die Update Operation (noch) nicht ausgeführt werden darf. Es würde nämlich ein neuer `Stand` 3000 gesetzt, was nicht korrekt ist, falls die erste Transaktion erfolgreich abschliesst.

In dieser Situation muss mit der Ausführung der `UPDATE` Operation der Transaktion 3 gewartet werden, bis die Transaktion 2 abgeschlossen ist (entweder mit `COMMIT` oder `ROLLBACK`).

`Xmax` als Schreibsperre

Betrachten wir ein Tupel mit einem `Xmax` Wert von einer Transaktion die *in Bearbeitung* ist. Wir können diesen `Xmax` Wert somit als Schreibsperre auf dem Tupel auffassen.

Mit diesem Mechanismus werden alle Tupel, welche in einer Transaktion durch `UPDATE` oder `DELETE` Operationen modifiziert werden, implizit für parallele Änderungsoperationen gesperrt.

Repeatable Read

Erstelle zu Beginn der Transaktion einen Snapshot und benutze diesen für die ganze Transaktion.

```
T2                              T3
BEGIN;
                                BEGIN;
                                SET TRANSACTION ISOLATION LEVEL
                                    REPEATABLE READ;
UPDATE Konti
SET Stand = Stand*2;
                                UPDATE Konti
                                SET Stand = Stand*3;
COMMIT;
                                COMMIT;
```

Dieser Ansatz verhindert auch Phantome.

Repeatable Read 2

Wenn die zweite Transaktion das `UPDATE` ausführen will, stellt sie fest, dass eine Schreibsperre besteht und wartet bis `T2` abgeschlossen ist.

Dann Fallunterscheidung ob `T2` erfolgreich war oder nicht.

1. Erfolgreiches Commit von `T2`. Wegen des Isolationsgrads von `T3` wird der Effekt der ersten Transaktion nie in `T3` sichtbar sein. Deshalb kann `T3` ihr `UPDATE` nie ausführen und wird automatisch zurückgesetzt. PostgreSQL erzeugt die Fehlermeldung:

   ERROR: could not serialize access due to concurrent update.

2. Rollback von `T2`. Durch das Rollback wird die Schreibsperre aufgehoben. Ausserdem enthält der Snapshot, der zu Beginn von `T3` erstellt wurde, die aktuellen Daten, da das `UPDATE` von `T2` rückgängig gemacht wurde. Somit kann `T3` mit der Abarbeitung der `UPDATE` Anweisung fortfahren und muss nicht zurückgesetzt werden.

Im ersten Fall muss erneute Ausführung von `T3` vom Benutzer initiiert werden.

Optimismus

Optimistische Strategie:
Wenn zwei Transaktionen nebeneinander initiiert werden, so wird mit der Abarbeitung von beiden begonnen und nur wenn es zu unlösbaren Konflikten kommt, wird eine Transaktion zurückgesetzt.

Pessimistische Strategie:
Zu Beginn einer Transaktion alle Objekte, welche in der Transaktion benötigt werden, sperren. Nur wenn alle Sperren erhältlich waren, wird mit der Abarbeitung der Transaktion begonnen. Es ist dann garantiert, dass die Transaktion ganz durchgeführt werden kann.

Der optimistische Ansatz bietet häufig eine deutlich bessere Performance als der pessimistische Ansatz. Falls nämlich nicht mit Snapshot gearbeitet wird, sondern mit Lese- und Schreibsperren, so können Schreiboperationen parallele Leseanweisungen blockieren, was in PostgreSQL nicht möglich ist.

Repeatable Read liefert nicht vollständige Isolation

```
T1                                  T2
BEGIN;                              BEGIN;
x:= SELECT COUNT(*)                 x:= SELECT COUNT(*)
    FROM Aerzte                         FROM Aerzte
    WHERE HatDienst=TRUE;               WHERE HatDienst=TRUE;
IF x>1 THEN                         IF x>1 THEN
  UPDATE Aerzte                       UPDATE Aerzte
  SET HatDienst=FALSE                 SET HatDienst=FALSE
  WHERE Name='Eva';                   WHERE Name='Tom';
COMMIT;                             COMMIT;
```

Beispiel: Repeatable Read gibt keine vollständige Isolation

Aerzte

Name	HatDienst
Eva	true
Tom	true

Nachdem beide Transaktionen im Isolationsgrad `REPEATABLE READ` ihr `COMMIT` aufgeführt haben, enthält die Tabelle `Aerzte` keinen Arzt mehr, der Dienst hat.

Aerzte

Name	HatDienst
Eva	false
Tom	false

Dies obwohl jede Transaktion für sich genommen garantiert, dass noch mindestens ein diensthabender Arzt übrigbleibt.

Echte Serialisierbarkeit

Gegeben sei eine parallele Ausführung von Transaktionen $\mathtt{T}_1, \ldots, \mathtt{T}_n$.

Diese parallele Ausführung heisst *echt serialisierbar*, falls es eine Reihenfolge $\mathtt{T}_{i_1}, \ldots, \mathtt{T}_{i_n}$ dieser Transaktionen gibt, so dass das Resultat der gegebenen parallelen Ausführung gleich ist wie das Resultat der sequentiellen Ausführung $\mathtt{T}_{i_1}, \ldots, \mathtt{T}_{i_n}$ dieser Transaktionen.

Sequentiell heisst, dass sich die Transaktionen zeitlich nicht überlappen (keine Parallelität).

Echte Serialisierbarkeit bedeutet also, dass die Transaktionen einander in keiner Art und Weise beeinflussen und somit vollständig isoliert sind.

Serializable

Um im Isolationsgrad `SERIALIZABLE` echte Serialisierbarkeit zu gewährleisten, verwendet PostgreSQL Snapshots, so wie sie bei `REPEATABLE READ` verwendet werden.

Zusätzlich wird noch Buch geführt über gewisse Abhängigkeiten zwischen den Transaktionen.

wr-Abhängigkeit `T1` schreibt einen Wert, welcher später von `T2` gelesen wird.

ww-Abhängigkeit `T1` schreibt eine Version eines Tupels, welche von `T2` durch eine neue Version ersetzt wird.

rw-Gegenabhängigkeit `T1` liest eine Version eines Tupels, welche später von `T2` durch eine neue Version ersetzt wird.

In allen drei Fällen muss `T2` nach `T1` ausgeführt werden.

Serialisierbarkeitsgraph

Ein *Serialisierbarkeitsgraph* ist ein gerichteter Graph, der wie folgt aufgebaut ist:

1. Jede Transaktion entspricht einem Knoten des Graphen.
2. Wenn `T2` von `T1` abhängig ist, so gibt es eine Kante von `T1` zu `T2`.

Serialisierbarkeit

Theorem

Eine parallele Ausführung von Transaktionen ist serialisierbar, genau dann wenn der entsprechende Serialisierbarkeitsgraph azyklisch ist.

Für die Implementierung echter Serialisierbarkeit in PostgreSQL ist zusätzlich noch folgendes Theorem relevant.

Theorem

Jeder Zyklus in einem Serialisierbarkeitsgraphen enthält eine Sequenz $\mathrm{T1} \xrightarrow{\mathrm{rw}} \mathrm{T2} \xrightarrow{\mathrm{rw}} \mathrm{T3}$.

Beachte, dass in diesem Theorem T1 und T3 dieselbe Transaktion bezeichnen können.

Implementation

Korollar

Gegeben sei eine parallele Ausführung von Transaktionen. Diese ist serialisierbar, falls gilt:

$$\begin{aligned} &\textit{der Serialisierbarkeitsgraph enthält keine Sequenz} \\ &\textit{der Form } \mathrm{T1} \xrightarrow{\mathrm{rw}} \mathrm{T2} \xrightarrow{\mathrm{rw}} \mathrm{T3}. \end{aligned} \tag{1}$$

Dabei ist Bedingung (1) hinreichend für die Serialisierbarkeit. Sie ist jedoch nicht notwendig.

PostgreSQL macht sich dieses Korollar zunutze, um echte Serialisierbarkeit zu implementieren. Im Isolationslevel `SERIALIZABLE` wird Buch geführt über die Abhängigkeiten zwischen den Transaktionen. Falls zwei aneinanderliegende rw-Abhängigkeiten auftreten, so wird eine der beteiligten Transaktionen abgebrochen.

Beispiel

```
T1                                  T2
BEGIN;                              BEGIN;
SET TRANSACTION ISOLATION           SET TRANSACTION ISOLATION
LEVEL SERIALIZABLE;                 LEVEL SERIALIZABLE;

SELECT COUNT(*)
FROM Aerzte
WHERE HatDienst=TRUE;
                                    SELECT COUNT(*)
                                    FROM Aerzte
                                    WHERE HatDienst=TRUE;
UPDATE Aerzte
SET HatDienst=FALSE
WHERE Name='Eva';
                                    UPDATE Aerzte
                                    SET HatDienst=FALSE
                                    WHERE Name='Tom';
COMMIT;                             COMMIT;
```

Beispiel

Wenn die zweite Transaktion ihre `COMMIT` Anweisung ausführen will, so erhalten wir folgende Fehlermeldung

> ERROR: could not serialize access due to read/write dependencies among transactions.

und `T2` wird automatisch zurückgesetzt.

Genau wie im Isolationslevel `REPEATABLE READ` müssen wir auch hier damit rechnen, dass eine Transaktion ihr `COMMIT` nicht ausführen kann und ein automatisches Rollback durchgeführt wird.