

# Datenbanken



## Berechnung von Normalformen

Thomas Studer

Institut für Informatik  
Universität Bern

## Repetition: Logische Folgerung

Seien

- $\mathcal{S} = (A_1, \dots, A_n)$  ein Schema,
- $F$  eine Menge von funktionalen Abhängigkeiten über  $\mathcal{S}$  und
- $X \rightarrow Y$  eine weitere funktionale Abhängigkeit über  $\mathcal{S}$ .

Wir sagen,  $X \rightarrow Y$  *folgt logisch aus*  $F$ , in Zeichen

$$F \models X \rightarrow Y ,$$

falls jede Instanz  $R$  von  $\mathcal{S}$ , welche alle Abhängigkeiten in  $F$  erfüllt, auch  $X \rightarrow Y$  erfüllt.

## Beispiel

Gegeben sei die Menge

$$F = \{W \rightarrow X, W \rightarrow Y, XY \rightarrow Z\}$$

von funktionalen Abhängigkeiten. Dann gilt unter anderem:

- ❶  $F \models W \rightarrow X,$
- ❷  $F \models W \rightarrow XY,$
- ❸  $F \models W \rightarrow Z.$

# Armstrong-Kalkül

Gegeben sei eine Menge  $F$  von funktionalen Abhängigkeiten über  $U$ . Dann wird  $F \vdash X \rightarrow Y$  für  $X, Y \subseteq U$  induktiv definiert durch:

## 1. Elemente von $F$ .

Ist  $X \rightarrow Y$  ein Element von  $F$ , so gilt  $F \vdash X \rightarrow Y$ .

## 2. Reflexivität.

Ist  $Y$  eine Teilmenge von  $X$ , so gilt  $F \vdash X \rightarrow Y$ .

## 3. Augmentation.

Aus  $F \vdash X \rightarrow Y$  und  $Z \subseteq U$  folgt  $F \vdash XZ \rightarrow YZ$ .

## 4. Transitivität.

Aus  $F \vdash X \rightarrow Y$  und  $F \vdash Y \rightarrow Z$  folgt  $F \vdash X \rightarrow Z$ .

## Beispiel

Betrachte:

$$\begin{aligned}U &:= \{\text{Autor}, \text{Jahrgang}, \text{Titel}\} \\ F_1 &:= \{\text{Autor} \rightarrow \text{Jahrgang}\} .\end{aligned}$$

Somit gilt mit Regel *Elemente von F*

$$F_1 \vdash \text{Autor} \rightarrow \text{Jahrgang} .$$

Dann folgt mit Regel *Augmentation* (für  $Z = \{\text{Autor}, \text{Titel}\}$ )

$$F_1 \vdash \{\text{Autor}, \text{Titel}\} \rightarrow \{\text{Autor}, \text{Jahrgang}, \text{Titel}\} .$$

# Theoreme

## Theorem (Korrektheit und Vollständigkeit)

*Ist  $F$  eine Menge von funktionalen Abhängigkeiten über  $U$ , so gilt für alle  $X, Y \subseteq U$*

$$F \vdash X \rightarrow Y \iff F \models X \rightarrow Y .$$

## Theorem (Charakterisierung der Hülle $F^+$ )

*Ist  $F$  eine Menge von funktionalen Abhängigkeiten über  $U$ , so gilt*

$$F^+ = \{X \rightarrow Y \mid F \models X \rightarrow Y\} = \{X \rightarrow Y \mid F \vdash X \rightarrow Y\} .$$

## Beispiel

Im vorherigen Beispiel haben wir im Armstrong-Kalkül

$$F_1 \vdash \{\text{Autor}, \text{Titel}\} \rightarrow \{\text{Autor}, \text{Jahrgang}, \text{Titel}\}$$

hergeleitet. Mit obigem Korollar folgt nun daraus

$$\{\text{Autor}, \text{Titel}\} \rightarrow \{\text{Autor}, \text{Jahrgang}, \text{Titel}\} \in F_1^+ .$$

# Folgerungen

## Theorem

Ist  $F$  eine Menge von funktionalen Abhängigkeiten über  $U$ , so gilt für alle  $X, Y, Z \subseteq U$ :

### 5. Vereinigung.

$$F \vdash X \rightarrow Y \text{ und } F \vdash X \rightarrow Z \implies F \vdash X \rightarrow YZ.$$

### 6. Zerlegung.

$$F \vdash X \rightarrow Y \text{ und } Z \subseteq Y \implies F \vdash X \rightarrow Z.$$

### 7. Einfachheit.

$$F \vdash X \rightarrow Y_1 Y_2 \dots Y_n \iff F \vdash X \rightarrow Y_i \text{ für alle } 1 \leq i \leq n.$$

## Definition (Einfache funktionale Abhängigkeit)

Funktionale Abhängigkeiten mit einelementigen rechten Seiten werden als *einfache funktionale Abhängigkeiten* bezeichnet.



# Attributhülle

## Definition (Attributhülle $X^+$ )

Gegeben seien eine Menge  $F$  von funktionalen Abhängigkeiten über der universellen Menge  $U$  sowie eine Menge  $X \subseteq U$ . Die *Attributhülle*  $X^+$  von  $X$  unter  $F$  ist dann definiert durch

$$X^+ := \{A \in U \mid F \vdash X \rightarrow A\} \text{ .}$$

## Lemma

### Lemma

*Für alle Mengen  $F$  von funktionalen Abhängigkeiten über der universellen Menge  $U$  sowie für alle Mengen  $X, Y \subseteq U$  gilt*

$$F \vdash X \rightarrow Y \iff Y \subseteq X^+ .$$

Beweis: Es sei  $Y$  die Attributmenge  $\{A_1, A_2, \dots, A_n\}$ .

Von links nach rechts. Es gelte also  $F \vdash X \rightarrow Y$ . Aufgrund der Zerlegungseigenschaft folgt  $F \vdash X \rightarrow A_i$  für alle  $1 \leq i \leq n$ . Dies ergibt  $Y \subseteq X^+$ .

Von rechts nach links. Sei  $Y \subseteq X^+$ . Mit der Definition von  $X^+$  folgt daraus  $F \vdash X \rightarrow A_i$  für alle  $1 \leq i \leq n$ . Mit der Vereinigungseigenschaft erhalten wir also unmittelbar  $F \vdash X \rightarrow Y$ .

## Algorithmus zur Berechnung von $X^+$

Gegeben seien eine universelle Menge  $U$  von Attributen, eine Menge  $F$  von funktionalen Abhängigkeiten über  $U$  sowie eine Menge  $X \subseteq U$ .

Eingabe:  $F, X$

$R := X; \quad alt\_R := \emptyset;$

WHILE  $R \neq alt\_R$  DO

$alt\_R := R;$

    FOR EACH  $V \rightarrow W$  IN  $F$  DO

        IF  $V \subseteq R$  THEN  $R := R \cup W$

Ausgabe:  $X^+ := R$

## Beispiel zum Algorithmus

Betrachte:

$$U = \{A, B, C, D, E, F, G\}$$

$$F = \{AC \rightarrow G, BD \rightarrow CE, E \rightarrow A, G \rightarrow BF\}$$

$$X = \{C, E\}$$

Iterative Berechnung von  $R$ :

$$\{C, E\}$$

$$\{C, E, A\}$$

$$\{C, E, A, G\}$$

$$\{C, E, A, G, B, F\} = X^+$$

# Überdeckungen

## Definition

Gegeben seien Mengen  $F$  und  $G$  von funktionalen Abhängigkeiten über  $U$ .

- ①  $G$  überdeckt  $F$ , in Zeichen  $F \leq G$ , falls  $F^+ \subseteq G^+$ .
- ②  $F$  und  $G$  sind äquivalent, falls  $F$  und  $G$  sich gegenseitig überdecken, das heisst  $F \simeq G \quad :\Longleftrightarrow \quad F \leq G \wedge G \leq F$ .

# Überdeckungen

## Lemma

*Gegeben seien Mengen  $F$  und  $G$  von funktionalen Abhängigkeiten über  $U$ . Dann gilt  $F \subseteq G^+ \iff F \leq G$ .*

Beweis: Rechts nach links: offensichtlich.

Links nach rechts: Sei  $F \subseteq G^+$ . Damit gilt

$$\begin{aligned} F^+ &= \{Y \rightarrow Z \mid F \vdash Y \rightarrow Z\} \\ &\subseteq \{Y \rightarrow Z \mid G^+ \vdash Y \rightarrow Z\} = (G^+)^+ = G^+ . \end{aligned}$$

Daraus folgt mit der vorhergehenden Definition sofort die Behauptung, dass  $F \leq G$  gilt.

## Test auf $F \leq G$

Eingabe:  $F, G$ .

Überprüfe für jedes  $Y \rightarrow Z \in F$ , ob  $Y \rightarrow Z \in G^+$  durch:

Berechne  $Y^+$  unter  $G$  und teste  $Z \subseteq Y^+$ .

Falls dies immer der Fall ist,

Ausgabe:  $F \leq G$ ; anderenfalls Ausgabe:  $F \not\leq G$ .

## Lemma

### Lemma

*Jede Menge  $F$  von funktionalen Abhängigkeiten über  $U$  ist zu einer Menge  $G$  äquivalent, die nur einfache funktionale Abhängigkeiten enthält, d.h. funktionale Abhängigkeiten mit einelementigen rechten Seiten.*

Beweis: Wir gehen aus von einer Menge  $F$  von funktionalen Abhängigkeiten über  $U$  und definieren

$$G_F := \{X \rightarrow A \mid \exists Y (X \rightarrow Y \in F \text{ und } A \in Y)\} .$$

Aufgrund der Zerlegungseigenschaft folgt  $X \rightarrow A \in F^+$  für alle  $A$  und  $Y$  mit  $A \in Y$  und  $X \rightarrow Y \in F$ . Folglich ist  $G_F \subseteq F^+$ .

Ist andererseits  $Y$  die Menge  $\{A_1, A_2, \dots, A_n\}$  und gilt

$$X \rightarrow A_i \in G_F \quad \text{für alle } 1 \leq i \leq n,$$

so folgt mit der Vereinigungseigenschaft auch  $X \rightarrow Y \in G_F^+$ . Daraus folgt  $F \subseteq G_F^+$ .

$G_F \subseteq F^+$  und  $F \subseteq G_F^+$  ergeben  $F \simeq G_F$ .

$G_F$  ist eine Menge von einfachen funktionalen Abhängigkeiten.



# Minimalität

## Definition

Eine Menge  $F$  von funktionalen Abhängigkeiten über  $U$  heisst *minimal*, falls folgende Bedingungen erfüllt sind:

- 1  $F$  enthält nur einfache funktionale Abhängigkeiten.
- 2 Keine funktionale Abhängigkeit in  $F$  ist redundant, d.h.

$$(\forall X \rightarrow A \in F)(F \setminus \{X \rightarrow A\} \not\subseteq F) . \quad (\text{M2})$$

- 3 Kein Attribut auf der linken Seite einer funktionalen Abhängigkeit aus  $F$  ist redundant, d.h.

$$(\forall X \rightarrow A \in F)(\forall Y \subsetneq X)((F \setminus \{X \rightarrow A\}) \cup \{Y \rightarrow A\} \not\subseteq F) \quad (\text{M3})$$

## Definition

Gegeben sei eine Menge  $F$  von funktionalen Abhängigkeiten über  $U$ . Eine *minimale Überdeckung* von  $F$  ist eine minimale Menge von funktionalen Abhängigkeiten, welche zu  $F$  äquivalent ist.

# Algorithmus für minimale Überdeckungen

Eingabe: Eine Menge  $F$  von funktionalen Abhängigkeiten über  $U$ .

- 1 Spalte alle nicht-einfachen funktionalen Abhängigkeiten in  $F$  auf. Nenne die neue Menge  $F'$ .
- 2 Entferne sukzessive alle redundanten Attribute im Sinne von (M3) der vorhergehenden Definition aus  $F'$ . Nenne die neue Menge  $F''$ .
- 3 Entferne sukzessive alle redundanten funktionalen Abhängigkeiten im Sinne von (M2) der vorhergehenden Definition aus  $F''$ . Nenne die neue Menge  $F'''$ .

Ausgabe:  $MU(F) := F'''$ .

## Beispiel

Attributmenge  $\{A, B, C\}$  mit  $F = \{AB \rightarrow C, A \rightarrow AB, B \rightarrow A\}$  .

1. Schritt: Die einzige nicht-einfache funktionale Abhängigkeit in  $F$  ist  $A \rightarrow AB$ . Wir spalten diese auf und erhalten so die Menge

$$F' = \{AB \rightarrow C, A \rightarrow A, A \rightarrow B, B \rightarrow A\} .$$

2. Schritt: Wir testen, ob  $A$  redundant in  $AB \rightarrow C$  ist. Dazu überprüfen wir, ob  $C \in \{B\}^+$  unter  $F'$  gilt.

Wegen  $\{B\}^+ = \{A, B, C\}$ , ist dies der Fall. Daher ist  $A$  redundant in  $AB \rightarrow C$  und wird gestrichen. Weitere redundante Attribute auf linken Seiten gibt es nicht. Also erhalten wir

$$F'' = \{B \rightarrow C, A \rightarrow A, A \rightarrow B, B \rightarrow A\} .$$

3. Schritt: Wir entfernen alle redundanten funktionalen Abhängigkeiten aus  $F''$ . Offensichtlich gilt  $A \in \{A\}^+$  unter  $F'' \setminus \{A \rightarrow A\}$  . Folglich ist  $A \rightarrow A$  in  $F''$  redundant und wird entfernt. Weitere Redundanzen gibt es dann nicht mehr. Es folgt also

$$\text{MU}(F) = \{B \rightarrow C, A \rightarrow B, B \rightarrow A\} .$$

## Bemerkung

Sei  $F$  eine Menge von funktionalen Abhängigkeiten. Dann kann es mehrere minimale Überdeckungen von  $F$  geben.

Betrachte die beiden Mengen von funktionalen Abhängigkeiten über der Attributmenge  $\{A, B, C\}$ :

$$F_1 := \{A \rightarrow B, B \rightarrow A, A \rightarrow C, C \rightarrow A\} ,$$

$$F_2 := \{A \rightarrow B, B \rightarrow C, C \rightarrow A\} .$$

Beide Mengen sind offensichtlich minimal und es gilt  $F_1^+ = F_2^+$ .

# Repetition

- ① jedes Schema kann verlustfrei in BCNF zerlegt werden;
- ② jedes Schema kann verlustfrei und abhängigkeiterhaltend in 3NF zerlegt werden.

# Algorithmus für die BCNF-Zerlegung

Gegeben seien ein Relationenschema  $\mathcal{S}$  mit einer Menge von funktionalen Abhängigkeiten  $F$ .

Eingabe:  $\mathcal{S}, F$

$\mathcal{Z} := \{\mathcal{S}\}$

WHILE es gibt  $\mathcal{S}_i \in \mathcal{Z}$  mit  $\mathcal{S}_i$  nicht in BCNF bez.  $\Pi_{\mathcal{S}_i}(F)$  DO

    wähle ein solches  $\mathcal{S}_i$

    wähle  $X \rightarrow A \in F^+$  mit

$X \subseteq \mathcal{S}_i, A \in \mathcal{S}_i, A \notin X, X \rightarrow \mathcal{S}_i \notin F^+$


$\mathcal{Z} := (\mathcal{Z} \setminus \{\mathcal{S}_i\}) \cup \{X \cup \{A\}, \mathcal{S}_i \setminus \{A\}\}$

Ausgabe:  $\mathcal{Z}$

Die so erhaltene Ausgabemenge  $\mathcal{Z}$  ist dann die gewünschte Zerlegung von  $\mathcal{S}$  in BCNF bezüglich  $F$ .

## Bild

Wähle ein Schema  $\mathcal{S}_i$  welches die BCNF Bedingungen verletzt bezüglich einer funktionalen Abhängigkeit  $X \rightarrow A$ . Das Schema  $\mathcal{S}_i$  wird dann wie folgt in zwei Schemata zerlegt:



Aus  $X \rightarrow A \in F^+$  folgt, dass diese Zerlegung von  $\mathcal{S}_i$  in  $\{X \cup \{A\}, \mathcal{S}_i \setminus \{A\}\}$  verlustfrei ist. Dieser Schritt wird solange wiederholt, bis alle Schemata der Zerlegung in BCNF sind.

## Beispiel

Wir betrachten

$$\mathcal{S}_3 = (\text{Stadt}, \text{Str}, \text{PLZ})$$

$$F_3 = \{ \{ \text{Stadt}, \text{Str} \} \rightarrow \{ \text{PLZ} \}, \quad \{ \text{PLZ} \} \rightarrow \{ \text{Stadt} \} \} .$$

Wir beginnen nun mit  $\mathcal{Z} := \{ \mathcal{S}_3 \}$ . Es gilt  $\mathcal{S}_3 \in \mathcal{Z}$  ist nicht in BCNF bezüglich  $F_3$ . Wir wählen nun eine funktionale Abhängigkeit  $X \rightarrow A \in F_3^+$ , welche die BCNF Bedingungen verletzt. Wir setzen

$$X := \{ \text{PLZ} \} \subseteq \mathcal{S}_3 \quad \text{und} \quad A := \text{Stadt} \in \mathcal{S}_3 .$$

Es gilt somit  $A \notin X$  und  $X \rightarrow \mathcal{S}_3 \notin F_3^+$ . Wir setzen  $\mathcal{Z}$  neu auf

$$\{ (\text{Stadt}, \text{PLZ}), (\text{Str}, \text{PLZ}) \} .$$

Jetzt sind alle Elemente von  $\mathcal{Z}$  in BCNF und der Algorithmus gibt die Zerlegung  $\mathcal{Z}$  als Resultat zurück.



## Algorithmus für die 3NF-Zerlegung

Gegeben Schema  $\mathcal{S}$  und *minimale* Menge  $F$  von funktionalen Abhängigkeiten. Für jede Abhängigkeit  $X \rightarrow A \in F$  definieren wir ein Schema  $\mathcal{S}_{X \rightarrow A}$ , so dass  $\mathcal{S}_{X \rightarrow A} = X \cup \{A\}$ .

Eingabe:  $\mathcal{S}, F$

$\mathcal{Z} := \{\mathcal{S}_{X \rightarrow A} \mid X \rightarrow A \in F\}$

IF kein  $\mathcal{S}_{X \rightarrow A} \in \mathcal{Z}$  enthält Schlüssel für  $\mathcal{S}$  bez.  $F$  THEN

    wähle Schema  $\mathcal{K}$ , welches Schlüssel für  $\mathcal{S}$  ist

$\mathcal{Z} := \mathcal{Z} \cup \{\mathcal{K}\}$

Ausgabe:  $\mathcal{Z}$

Die so erhaltene Ausgabemenge  $\mathcal{Z}$  ist dann die gewünschte Zerlegung von  $\mathcal{S}$  in 3NF bezüglich  $F$ .

## Beispiel

Betrachte:

$$\mathcal{S}_2 = (\text{BuchId}, \text{Autor}, \text{Jahrgang}, \text{Titel})$$
$$F_2 = \{ \{ \text{BuchId} \} \rightarrow \{ \text{Autor}, \text{Jahrgang}, \text{Titel} \}, \\ \{ \text{Autor} \} \rightarrow \{ \text{Jahrgang} \} \} .$$

Zuerst berechnen wir die minimale Überdeckung  $\text{MU}(F_2)$  von  $F_2$ .

- 1 Durch Aufspalten erhalten wir

$$F'_2 := \{ \text{BuchId} \rightarrow \text{Autor}, \text{BuchId} \rightarrow \text{Jahrgang} \\ \text{BuchId} \rightarrow \text{Titel}, \text{Autor} \rightarrow \text{Jahrgang} \} .$$

- 2 Redundante Attribute entfernen. Die linken Seiten sind alle ein-elementig. Somit haben wir  $F''_2 := F'_2$  .
- 3 Redundante Abhängigkeiten entfernen. Wir finden

$$\text{Jahrgang} \in \text{BuchId}^+ \text{ unter } F''_2 \setminus \{ \text{BuchId} \rightarrow \text{Jahrgang} \} .$$

Somit gilt  $F''_2 \setminus \{ \text{BuchId} \rightarrow \text{Jahrgang} \} \simeq F''_2$  und wir setzen

$$\text{MU}(F_2) := F'''_2 := F''_2 \setminus \{ \text{BuchId} \rightarrow \text{Jahrgang} \} .$$

## Beispiel

Als Input für den 3NF-Algorithmus verwenden wir nun  $\mathcal{S}_2$  und  $\text{MU}(F_2)$ .

$$\mathcal{S}_2 = (\text{BuchId}, \text{Autor}, \text{Jahrgang}, \text{Titel})$$

$$\text{MU}(F_2) := \{ \text{BuchId} \rightarrow \text{Autor}, \text{BuchId} \rightarrow \text{Titel}, \text{Autor} \rightarrow \text{Jahrgang} \}$$

Im ersten Schritt erhalten wir so die Zerlegung

$$\mathcal{Z} = \{ (\text{BuchId}, \text{Autor}), (\text{BuchId}, \text{Titel}), (\text{Autor}, \text{Jahrgang}) \}.$$

Das Schema  $(\text{BuchId}, \text{Autor}) \in \mathcal{Z}$  enthält einen Schlüssel für  $\mathcal{S}_2$  bezüglich  $\text{MU}(F_2)$ . Somit müssen wir im zweiten Schritt kein Schema hinzufügen.

Damit ist  $\mathcal{Z}$  eine verlustfreie und abhängigkeiterhaltende Zerlegung des Schemas  $\mathcal{S}_2$  in die dritte Normalform.

## Beispiel : Schlüssel hinzufügen

Betrachte

$$\mathcal{S} := \{\underline{A}, \underline{B}, C\}$$

$$F := \{B \rightarrow C\}$$

Somit ist  $\{A, B\}$  ein Schlüssel für das Schema  $\mathcal{S}$

Nach Schritt 1 des Algorithmus haben wir

$$\mathcal{Z} = \{ (B, C) \} .$$

Wir sehen:

- $\mathcal{Z}$  ist keine Zerlegung.
- $\mathcal{Z}$  enthält kein Schema, das einen Schlüssel für  $\mathcal{S}$  enthält.

Nach Schritt 2 des Algorithmus haben wir

$$\mathcal{Z} = \{ (B, C) (A, B) \} .$$